Memoria tecnica - Corporativo JUC

Pipeline de datos (ETL + Cloud + Analisis)

Corporativo JUC

Indice

Indice 2
Resumen ejecutivo 3
Objetivo y alcance 3
Arquitectura 4
Estructura del repositorio 4
Parte I - Fuentes de datos 5
Parte II - ETL 6
Transformaciones (T01..T10) 6
Validacion de minimos 7
Parte III - PostgreSQL 7
Modelo relacional (3FN) 7
Indices y EXPLAIN ANALYZE 8
Consultas 8
Parte IV - MongoDB 9
Colecciones 9
Indices 9
Consultas y pipelines 9
Parte V - Integracion SQL + NoSQL 10
Parte VI - Cloud 10
Parte VII - Visualizacion 11
Operacion y pruebas 12
Limitaciones y trabajo futuro 12
Anexos 13
A. Diccionario de datos (resumen) 13
B. Consultas y evidencia 13
C. Indice de figuras 13

Resumen ejecutivo

Corporativo JUC S.A. de C.V. es una empresa ficticia de electronica en Mexico. Este proyecto construye un pipeline de ingenieria de datos completo: genera tres fuentes crudas con errores intencionales, las limpia con 10 transformaciones auditables, las carga en PostgreSQL (modelo relacional 3FN) y en MongoDB (documentos), responde 47 preguntas de negocio y produce 12 visualizaciones interactivas.

Cifras de la ultima ejecucion (semilla `SEED = 20260904`):

Indicador	Valor
Facturacion (pedidos completados)	$127,336,206.51
Pedidos completados / totales	1,483 / 2,259
Ticket promedio	$85,863.93
Tasa de cancelacion	34.35%
Unidades vendidas	10,782
Utilidad bruta	$37,982,053.12
Margen real ponderado	29.46%
Clientes con al menos un pedido	1,314
Productos vendidos	514 de 606
Preguntas respondidas	20 SQL + 12 pipelines + 15 `find/count`

El proyecto es **reproducible**: la semilla fija los datos y una sola orden (`python src/run_all.py`) regenera todo el pipeline.

Objetivo y alcance

Objetivo general: demostrar un flujo de ingenieria de datos de extremo a extremo, desde fuentes crudas y sucias hasta analisis y visualizacion, usando PostgreSQL, MongoDB y servicios cloud.

Objetivos especificos:

- Generar fuentes con errores intencionales y documentar su calidad.
- Implementar un ETL con 10 transformaciones y campos derivados.
- Modelar y cargar un esquema relacional normalizado (3FN) en PostgreSQL.
- Modelar colecciones documentales e implementar consultas y pipelines en MongoDB.
- Integrar ambos motores con Pandas para responder preguntas que ninguno resuelve solo.

- Desplegar en servicios cloud (Supabase y MongoDB Atlas) con degradacion local.
- Producir un reporte con indicadores y visualizaciones.

Fuera de alcance: datos reales de produccion, alta disponibilidad 24/7, streaming en tiempo real y modelos predictivos avanzados.

Arquitectura

Cuatro componentes obligatorios:

1. **ETL (Python + Pandas):** extrae, limpia, homologa y deriva campos; deja evidencia de calidad.
2. **PostgreSQL:** datos estructurados y transaccionales (clientes, pedidos, detalle, pagos) con integridad referencial.
3. **MongoDB:** documentos con atributos variables (catalogo semiestructurado, resenas y eventos de navegacion).
4. **Cloud:** PostgreSQL administrado en Supabase y MongoDB Atlas; almacenamiento y computo simulados con un arbol de carpetas portable.

```
Fuentes crudas                 ETL                        Almacenes
---------------          -----------------        -------------------------
CSV (A)          ->  extraer -> transformar  ->  PostgreSQL (3FN + vista)
JSON (B)         ->  (10 reglas) -> cargar   ->  MongoDB (documentos)
Sheets/XLSX (C)  ->                          ->  data/sql, data/nosql

Almacenes -> Analisis (Pandas) -> Reportes CSV + Visualizacion (Plotly/HTML)
```

El flujo se orquesta con `src/run_all.py` en cinco etapas: `generar -> etl -> integracion -> analisis -> graficos` (y `tests` opcional con `--con-tests`).

Estructura del repositorio

```
Proyecto_BigData/
  src/                      codigo del pipeline
    config.py               rutas, semilla, minimos, catalogos
    utils.py                logging, tracker de calidad, tablas
    generate_sources.py     Parte I: 3 fuentes crudas con errores
    etl_extract.py          extraccion + evidencia por tabla/columna
    etl_transform.py        10 transformaciones (T01..T10)
    etl_load.py             3FN + datasets analiticos + documentos
    integration.py          DDL, carga, 20 SQL, 12 pipelines, 15 find
    analysis.py             19 analisis de negocio
    viz.py                  12 graficos Plotly -> HTML
```

```
  er_diagram.py          diagrama ER (PNG) + justificacion 3FN
  run_all.py             orquestador de etapas
tests/                   161 pruebas (transform, integration, analysis, run_all)
docs/                    memoria (.md/.docx/.pdf) y guion de presentacion
.opencode/skills/        project-docs, data-pipeline, informe-juc
data/
  raw/csv, raw/json, raw/sheets     fuentes crudas
  processed/tablas                  tablas normalizadas 3FN
  processed/dataset_postgresql.csv  dataset para PostgreSQL
  processed/dataset_mongodb.json    documentos para MongoDB
  processed/integracion/            SQLite local (solo modo local)
  sql/                              01_ddl.sql, 02_consultas.sql, EXPLAIN
  nosql/                            NDJSON, indices.json, pipelines y consultas
  reports/                          calidad, consultas_sql/, consultas_mongodb/,
                                    analisis/, modelo_relacional.md/.png,
                                    integracion_entorno.md, figuras_indice.csv,
                                    reporte.html
  figures/                          12 HTML + plotly.min.js
logs/                    pipeline.log y artefactos de referencia
README.md                guia principal
README_CARPETAS.md       mapa detallado de carpetas
GUIA_CONEXION_NUBE.md    configuracion de Supabase y Atlas
.env.example             plantilla de credenciales (sin secretos)
```

Parte I - Fuentes de datos

Se generan tres fuentes con formatos distintos y errores deliberados:

Fuente	Origen	Formato	Errores inyectados
A	CSV	`.csv`	duplicados, ciudades con varias grafias, precios como texto (`$1,234.56`), fechas ambiguas, PK no numericas, nulos y tipos mezclados
B	JSON	`.json`	estructura semiestructurada, atributos variables por familia, anidamiento
C	Google Sheets	`.xlsx`	ciudades y categorias sucias, regiones inconsistentes con la ciudad

Archivos:

- `data/raw/csv/`: `clientes.csv`, `productos.csv`, `pedidos.csv`, `detalle_pedido.csv`, `pagos.csv`.

- `data/raw/json/`: `productos_semiestructurados.json`, `resenas.json`, `actividad_usuario.json`.
- `data/raw/sheets/`: `sucursales.xlsx`, `proveedores.xlsx`, `promociones.xlsx`, `objetivos_venta.xlsx`.

La Fuente C se documenta como **Google Sheets exportado a `.xlsx`**: en produccion se leeria con la Sheets API o el enlace de exportacion, con las mismas columnas.

Parte II - ETL

Transformaciones (T01..T10)

ID	Transformacion	Efecto
T01	Eliminacion de duplicados	una fila por clave natural
T02	Normalizacion de texto	recorta, colapsa espacios, unifica mayusculas
T03	Tratamiento de nulos	imputacion por regla de negocio o marca `Sin ...`
T04	Correccion de tipos	enteros, decimales y booleanos con `Int64` nullable
T05	Estandarizacion de fechas	formatos multiples -> `datetime64[ns]`
T06	Validacion de precios	descarta negativos y texto no convertible
T07	Validacion de cantidades	enteros positivos y coherencia de subtotales
T08	Unificacion de categorias y ciudades	`PC/COMPUTADORAS` -> `Computadoras`; `Ver./VERACRUZ` -> `Veracruz`
T09	Eliminacion de columnas	quita columnas redundantes o vacias
T10	Campos derivados	`anio_mes`, margen, rango de precio, conciliacion, etc.

Cada transformacion registra filas antes/despues, registros afectados y la regla aplicada en `data/reports/calidad_transformaciones.csv` (90 filas de evidencia en la ultima corrida).

Validacion de minimos

`data/reports/validacion_minimos.csv` demuestra que se superan los minimos del enunciado:

Informacion	Destino	Minimo	Final	Cumple
Clientes	clientes	1000	1862	SI
Productos	productos	500	606	SI
Pedidos	pedidos	2000	3277	SI
Detalles de pedidos	detalle_pedido	1000	3891	SI
Resenas	resenas (MongoDB)	2000	2475	SI
Navegacion	actividad_usuario (MongoDB)	1000	4236	SI

Parte III - PostgreSQL

Modelo relacional (3FN)

El esquema operativo tiene las 6 tablas exigidas: `clientes`, `productos`, `categorias`, `pedidos`, `detalle_pedido` y `pagos`. Se anaden dos dimensiones (`dim_ciudades`, `dim_sucursales`) y una tabla de hechos analitica (`fact_ventas`), mas la vista `v_resumen_ventas`.

Restricciones implementadas:

- **PK** en todas las tablas.
- **FK** entre pedidos-clientes, pedidos-sucursales, detalle-pedido, detalle-producto, pagos-pedido, productos-categoria y clientes-ciudad.
- **UNIQUE** en nombres de categoria, ciudad y sucursal, y en el nombre de producto.
- **NOT NULL** en las columnas clave.
- **CHECK** de precios positivos, margen entre 0 y 1, cantidades positivas, descuentos coherentes y total = subtotal - descuento.

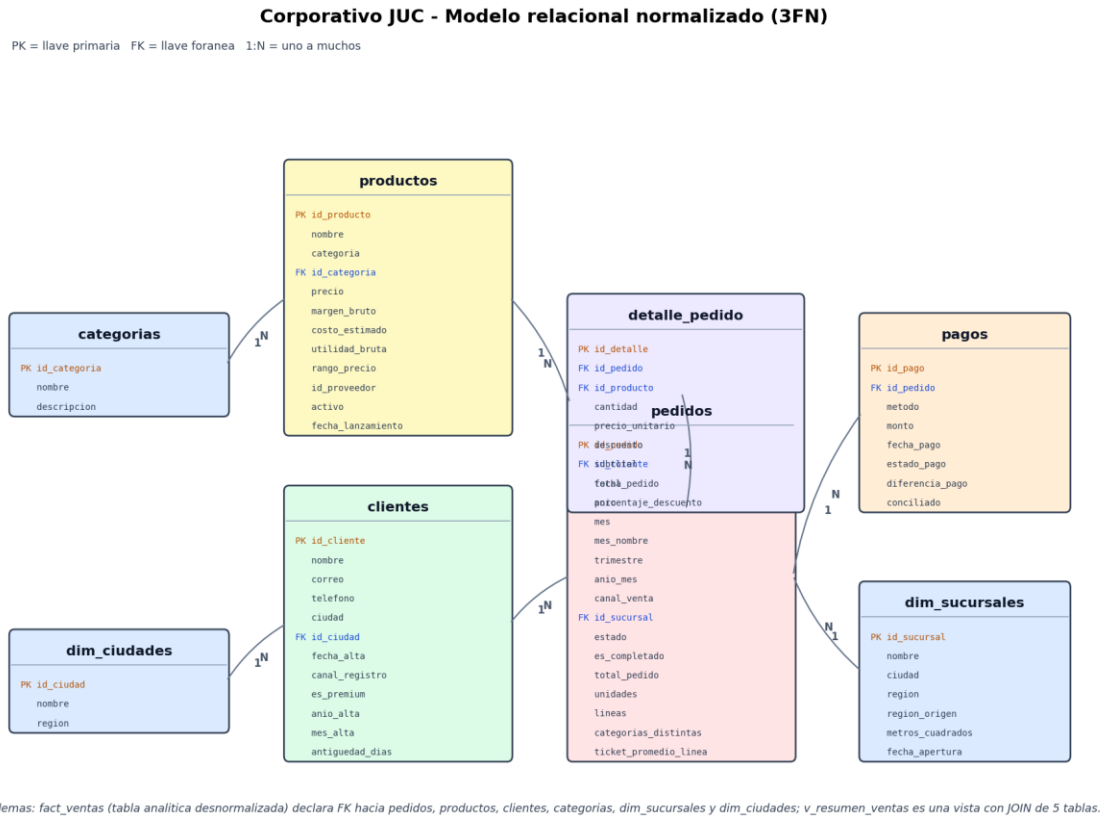


Diagrama ER del modelo relacional

DDL completo: `data/sql/01_ddl.sql` (copia en `data/reports/consultas_sql/01_ddl.sql`).

Indices y EXPLAIN ANALYZE

Se definen **20 indices** sobre claves foraneas y columnas de filtro/orden (fechas, estado, canal, categoria, rango de precio, conciliacion). El archivo `data/sql/03_explain_analyze.md` compara el plan **antes y despues** de crear el indice: el plan pasa de un recorrido completo a `SEARCH ... USING INDEX`, con una mejora de **4.03x** (0.874 ms sin indice frente a 0.217 ms con el indice `ix_fact_anio_mes`).

Consultas

Se ejecutan **20 consultas** (Q01..Q20) contra PostgreSQL. Cubren `INNER JOIN`, `LEFT JOIN`, una consulta de 4+ tablas (Q19 usa 6), agregaciones `COUNT/SUM/AVG/MIN/MAX`, `GROUP BY`, `HAVING`, `ORDER BY`, subconsultas y el uso de la vista. Cada resultado se guarda en

`data/reports/consultas_sql/Qxx_*.csv` y el resumen en `00_resumen_consultas.csv`.

Ejemplos de preguntas respondidas: top de productos y clientes, evolucion mensual, mix por categoria, ticket por canal, productos nunca vendidos, conciliacion de pagos, Pareto y detalle 360 del pedido.

Parte IV - MongoDB

Colecciones

Coleccion	Documentos	Contenido
productos	606	catalogo con subdocumento `atributos` variable por familia
resenas	2475	resenas con cliente anidado, calificacion y verificacion
actividad_usuario	4236	eventos de navegacion, visualizacion y compra

Documentos en `data/nosql/*.ndjson`; definicion de indices en `data/nosql/indices.json`.

Indices

12 indices en total (4 por coleccion): clave natural, categoria+precio, atributo variable (`sparse`), rango de precio, resenas por producto/cliente, calificacion y fecha; navegacion por producto, usuario, embudo y categoria.

Consultas y pipelines

- **15 consultas** `find`/`countDocuments` (B01..B15) que usan `sort`, `limit`, `countDocuments` y los operadores `$gt`, `$lt`, `$gte`, `$lte`, `$in`, `$and`, `$or`.
- **12 pipelines de agregacion** (A01..A12) con `$match`, `$group`, `$sort`, `$project`, `$limit`, `$unwind` y `$lookup`. Responden, entre otras:

- A02: productos muy vistos y nunca vendidos (inversion que no convierte).
- A08: consulta dinamica sobre `atributos.procesador`, presente solo en una familia.
- A11: calificacion promedio por categoria.
- A12: actividad de navegacion por ciudad.

Codigo en `data/nosql/01_pipelines.js` y `data/nosql/02_consultas.js`; resultados en `data/reports/consultas_mongodb/A*.csv` y `B*.csv`.

Parte V - Integracion SQL + NoSQL

La pregunta central es: **¿los productos mas vistos son los mas vendidos?** No se puede responder con un solo motor, porque las ventas viven en PostgreSQL y la navegacion en MongoDB. Se resuelve en Python/Pandas:

5. De PostgreSQL se extrae `id_producto, cantidad_vendida, ingresos`.
6. De MongoDB se extrae `id_producto, numero_visualizaciones`.
7. Se cruzan con `merge` por `id_producto`.

Resultado (A10): **Pearson +0.323** entre visitas y unidades vendidas para los productos visitados y vendidos. Al ampliar la poblacion, la correlacion baja: **Pearson +0.146** sobre todos los productos y **+0.104** solo entre los visitados; el **Spearman +0.270** sobre todos los productos confirma que la relacion es debil y no monotona perfecta. La conclusion es que la navegacion ayuda pero no garantiza la venta: hay 63 productos con trafico y cero unidades vendidas, de los 92 del catalogo (606) que nunca se vendieron.

Artefactos: `11_correlacion_visitas_ventas.csv`, `12_dispersion_visitas_ventas.csv`, `13_inventario_muerto.csv`, `14_under_exposure.csv` y `20_cuadrantes_visitas_ventas.csv`.

Parte VI - Cloud

Componente	Implementacion	Estado
Cloud Database (SQL)	PostgreSQL 17 en Supabase (Session pooler IPv4)	real
Cloud Database (NoSQL)	MongoDB Atlas 8.0 (cluster M0)	real
Cloud Storage	arbol local `data/` con el layout del enunciado	simulado
Cloud Computing	ejecucion portable de Python (VM/CI/contenedor)	simulado/portatil

Configuracion en `.env` (ignorado por git; plantilla en `.env.example`):

- `SUPABASE_HOST`, `SUPABASE_PORT`, `SUPABASE_DATABASE`, `SUPABASE_USER`,

`SUPABASE_PASSWORD`, `PG_SSLMODE=require`.

- `MONGO_URI`, `MONGO_DB=juc`.
- Variables de control: `FORZAR_SQLITE`, `SIN_POSTGRES`, `SIN_MONGO`.

Sin credenciales, el pipeline **degrada** a SQLite y NDJSON sin fallar, de modo que tambien se reproduce sin infraestructura.

Layout de almacenamiento (punto 26):

```
data/raw/{csv,json,sheets}          crudo (fuentes A/B/C)
data/processed/tablas               tablas normalizadas 3FN
data/processed/dataset_*.{csv,json} datasets para los motores
data/sql/                           DDL, consultas y EXPLAIN
data/nosql/                         colecciones, pipelines, consultas, indices
data/reports/                       resultados, evidencia y reportes
data/figures/                       visualizaciones
```

Parte VII - Visualizacion

Se generan **12 visualizaciones interactivas** con Plotly (HTML): hover con el valor exacto, zoom y series aislables. Todas se reunen en `data/reports/reporte.html`; cada una tambien existe por separado en `data/figures/`.

#	Visualizacion	Que muestra
01	Serie temporal de ventas	facturacion mensual y ticket promedio
02	Mix por categoria	participacion y margen por familia
03	Ticket y margen por canal	facturacion y margen real por canal
04	Ley de Pareto	concentracion de la venta
05	Segmentacion RFM	clientes por segmento y su peso
06	Embudo navegacion-compra	eventos por paso y caidas
07	Correlacion navegacion-venta	dispersion y ajuste lineal
08	Visitas sin venta	inventario muerto por trafico
09	Under-exposure	mucho volumen con pocas visitas
10	Descuentos vs margen	margen por rango de descuento
11	Calificaciones	distribucion de resenas y tasa positiva
12	Facturacion por sucursal	venta y ticket por sucursal

Indicadores principales: facturacion, pedidos, ticket, cancelacion, unidades, utilidad, margen, clientes, productos vendidos y concentracion (Pareto).

Operacion y pruebas

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
.\.venv\Scripts\python.exe src\run_all.py
.\.venv\Scripts\python.exe src\run_all.py --con-tests
```

Etapas y flags: `--listar`, `--sin-generar`, `--solo <etapas>`, `--con-tests`. El pipeline se detiene en la primera etapa que falla.

Estado verificado de la ultima corrida:

Comprobacion	Resultado
Pruebas (`pytest`)	161 passed
Consultas SQL	20/20 OK
Pipelines NoSQL	12/12 OK
Consultas `find/count`	15/15 OK
Visualizaciones	12/12 OK
Diagrama ER	generado
Nulos en el dataset final	0

Limitaciones y trabajo futuro

- Datos **sinteticos**: las conclusiones describen la empresa ficticia, no un negocio real.
- Pandas trabaja en memoria; para volumenes mayores habria que migrar el ETL a Spark/Dask.
- Cloud Storage y Cloud Computing estan **simulados** con el arbol local y la portabilidad del codigo; no se aprovisionan buckets ni VMs.
- El reporte visual es HTML: no se incrusta en Word; se entrega como `reporte.html` y se imprime a PDF desde el navegador si hace falta.
- Mejoras: orquestacion programada (cron/Airflow), monitoreo de calidad, pruebas de carga y un modelo predictivo de churn/recomendacion.

Anexos

A. Diccionario de datos (resumen)

- clientes: id_cliente, nombre, ciudad, region, es_premium, antiguedad_dias.
- productos: id_producto, nombre, id_categoria, categoria, precio, costo, margen_bruto, rango_precio.
- pedidos: id_pedido, id_cliente, id_sucursal, fecha_pedido, anio_mes, estado, canal_venta, total_pedido.
- detalle_pedido: id_detalle, id_pedido, id_producto, cantidad, precio_unitario, descuento, subtotal, total.
- pagos: id_pago, id_pedido, metodo, monto, estado_pago, diferencia_pago, conciliado.
- categorias: id_categoria, nombre.

B. Consultas y evidencia

- data/reports/consultas_sql/: 01_ddl.sql, 02_consultas.sql, 03_explain_analyze.md, 04_explain_analyze.csv, Q01..Q20.
- data/reports/consultas_mongodb/: 01_pipelines.js, 02_consultas.js, A01..A12, B01..B15.
- data/reports/calidad_transformaciones.csv y validacion_minimos.csv.

C. Indice de figuras

data/reports/figuras_indice.csv lista las 12 visualizaciones con su archivo, estado y tamano. El reporte unificado es data/reports/reporte.html.

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
.\.venv\Scripts\python.exe src\run_all.py
.\.venv\Scripts\python.exe src\run_all.py --con-tests
```